FIAP • TECH CHALLENGE — FASE 2

WineQT

Classificação da qualidade de vinhos com Machine Learning

DOCUMENTAÇÃO TÉCNICA E EXECUTIVA

Propósito deste documento Consolidar em uma única narrativa o problema, a análise exploratória, a preparação dos dados, os modelos, os resultados, as decisões metodológicas, as contribuições da equipe e a situação dos entregáveis. Este material complementa — mas não substitui — o código, os notebooks, a apresentação executiva e o vídeo.

Equipe WineQT
Ana Carolina Mendes Rosa • Gabriel Teixeira Pimenta
Rayra Godinho Viana Bahia • Joey da Silva Dagmar

02 de novembro de 2026

Repositório do projeto: https://github.com/acmrosax/Tech-Challeng

Sumário

- 1. Resumo executivo
- 2. Enunciado, contexto e objetivo
- 3. Base de dados e variáveis
- 4. Análise exploratória (EDA)
- 5. Preparação e qualidade dos dados
- 6. Desenvolvimento dos modelos
- 7. Avaliação e comparação
- 8. Interpretação e implicações para a produção
- 9. Organização do projeto e reprodutibilidade
- 10. Equipe, responsabilidades e integração
- 11. Entregáveis oficiais e situação no Trello
- 12. Limitações, riscos e próximos passos
- 13. Conclusão
- 14. Fontes e materiais consultados

1. Resumo executivo

O projeto WineQT desenvolve uma solução de classificação binária para estimar se uma amostra de vinho pertence à categoria de alta qualidade, a partir de 11 características físico-químicas. A classificação adotada considera alta qualidade para notas quality ≥ 7 e baixa/média qualidade para notas quality < 7.

O trabalho percorreu compreensão do problema, análise exploratória, pré-processamento, desenvolvimento de dois classificadores, avaliação comparativa e interpretação dos resultados. Foram comparadas Regressão Logística e Random Forest.

Indicador	Resultado consolidado
Base inicial da EDA	1.143 registros
Base após remoção de duplicatas	1.018 registros
Divisão	814 treino (80%) • 204 teste (20%)
Preditoras	11 variáveis físico-químicas
Modelos	Regressão Logística e Random Forest
Configuração recomendada	Random Forest com limiar de decisão 0,25
Resultado no teste	F1-score 62,50% • Recall 74,07% • Precisão 54,05% • AUC-ROC 0,9317
Entregáveis previstos	Repositório GitHub • apresentação executiva • vídeo de até 5 minutos

Síntese da decisão O Random Forest com limiar 0,25 apresentou o maior F1-score entre as configurações comparadas e identificou 20 dos 27 exemplos positivos do conjunto de teste. A escolha aumenta a identificação da classe positiva em relação ao Random Forest padrão, aceitando mais falsos positivos.

2. Enunciado, contexto e objetivo

O enunciado da FIAP apresenta o desafio “Classificando a qualidade de vinhos com Machine Learning”. O contexto parte da avaliação sensorial tradicional, que depende da experiência de especialistas e pode envolver subjetividade e tempo. O projeto investiga se dados físico-químicos podem apoiar a previsão da qualidade.

O objetivo é desenvolver uma pipeline de análise e modelagem capaz de prever a classificação binária de qualidade usando as variáveis disponíveis no Wine Quality Dataset.

2.1 Definição do problema

Elemento	Definição do projeto
Problema	Classificar a qualidade de uma amostra de vinho a partir de medições físico-químicas.
Variável original	quality — nota atribuída à amostra.
Variável-alvo	quality_class.
Classe 0	quality < 7 — baixa/média qualidade.
Classe 1	quality ≥ 7 — alta qualidade.
Tipo de tarefa	Classificação binária supervisionada.

2.2 Etapas previstas no enunciado

Etapa FIAP	Escopo solicitado	Evidência no projeto
1. Compreensão	Contextualizar o problema e definir o alvo binário.	Definição de quality_class e objetivo de classificação.
2. EDA	Distribuições, correlações, outliers/inconsistências e balanceamento.	Notebooks, gráficos e síntese dos achados.
3. Pré-processamento	Dados faltantes, padronização/normalização e feature engineering se relevante.	Notebook e relatório da Etapa 3.
4. Modelagem	Treinar pelo menos dois classificadores e comparar.	Regressão Logística e Random Forest.
5. Avaliação	Métricas adequadas e comparação dos modelos.	Métricas, matrizes de confusão e validação do limiar.
6. Interpretação	Variáveis influentes e possíveis implicações para produção.	Importância de variáveis, interpretação e ressalvas.

Escopo acadêmico O enunciado exige três entregáveis: link do repositório GitHub com os códigos, apresentação executiva com storytelling da EDA em PPT ou PDF e vídeo executivo de até cinco minutos. O DOCX atual é documentação complementar, não um quarto entregável obrigatório.

3. Base de dados e variáveis

A equipe utilizou o Wine Quality Dataset (WineQT), disponibilizado publicamente no Kaggle. A base inicial analisada na EDA contém 1.143 registros e 13 colunas: 11 medições físico-químicas, a nota quality e o identificador Id.

Variável	Descrição	Variável	Descrição
fixed acidity	Acidez fixa	volatile acidity	Acidez volátil
citric acid	Ácido cítrico	residual sugar	Açúcar residual
chlorides	Cloretos	free sulfur dioxide	Dióxido de enxofre livre
total sulfur dioxide	Dióxido de enxofre total	density	Densidade
pH	Potencial hidrogeniônico	sulphates	Sulfatos
alcohol	Teor alcoólico	quality	Nota de qualidade (alvo original)
Id	Identificador da amostra	—	—

As 11 variáveis físico-químicas são utilizadas como preditoras. Id é mantido apenas para rastreabilidade e quality não entra como preditora, pois é a origem direta do alvo quality_class.

3.1 Distribuição original da qualidade

Nota	Registros	Percentual aproximado
3 e 4	39	3,4%
5	483	42,3%
6	462	40,4%
7	143	12,5%
8	16	1,4%
Total	1.143	100%

As notas 5 e 6 concentram 82,7% da base. As notas 7 e 8 representam 13,9% dos registros originais, indicando desbalanceamento da classe positiva. A média de quality indicada na apresentação é aproximadamente 5,66.

4. Análise exploratória (EDA)

A EDA investigou a estrutura da base, tipos de dados, estatísticas descritivas, distribuição das notas, distribuição das variáveis físico-químicas, correlações, valores atípicos e balanceamento das classes.

4.1 Principais relações com quality

Variável	Correlação apresentada	Interpretação descritiva
Álcool	+0,485	Associação positiva mais forte entre as variáveis destacadas.
Acidez volátil	−0,407	Associação negativa com a nota quality.
Sulfatos	+0,258	Associação positiva.
Ácido cítrico	+0,241	Associação positiva.

As correlações são tratadas como associações estatísticas, não como relações causais. O relatório de preparação destaca taxas de outliers pelo IQR mais elevadas em residual sugar (9,62%) e chlorides (6,74%), sem que isso tenha levado à exclusão automática dos registros.

O storytelling da apresentação executiva acompanha essa sequência: problema → conhecimento dos dados → distribuição e desbalanceamento → correlações e outliers → preparação → modelos → recomendação e limitações.

Leitura da EDA O desbalanceamento é uma característica central do problema. Por isso, a acurácia isolada não é suficiente para avaliar os classificadores; precisão, recall, F1-score e matriz de confusão ajudam a compreender o comportamento na classe minoritária.

5. Preparação e qualidade dos dados

5.1 Ausentes, duplicatas e consistência

O relatório da Etapa 3 registra zero valores ausentes e zero inconsistências nas verificações de domínio descritas. A contagem inicial de duplicatas considerava todas as colunas, inclusive Id; como o identificador é diferente entre linhas, essa contagem não identificava amostras repetidas.

Verificação	Resultado registrado
Valores ausentes	0 em todas as colunas.
Duplicatas incluindo Id	0.
Duplicatas ignorando Id (11 medições + quality)	125 cópias excedentes.
Linhas pertencentes a grupos duplicados	239.
Grupos com medições idênticas e notas diferentes	0.
Cópias excedentes pertencentes à classe positiva	22.

Foram removidas 125 cópias excedentes, mantendo a primeira ocorrência de cada combinação de medições físico-químicas e quality. A justificativa é evitar que a mesma amostra apareça simultaneamente em treino e teste, o que poderia produzir avaliação excessivamente otimista.

Redução da base 1.143 registros originais − 125 cópias excedentes = 1.018 registros após a preparação. A proporção da classe positiva passou de 13,91% para 13,46%.

5.2 Alvo, identificador e divisão

- Foi criada a variável quality_class: 1 quando quality ≥ 7 e 0 quando quality < 7.
- Id foi excluído das preditoras por ser identificador de linha, não uma medição físico-química; foi preservado separadamente para rastreabilidade.
- quality foi excluída das preditoras por ser a origem direta da variável-alvo.
- As 11 medições físico-químicas compõem X; quality_class compõe y.
- A divisão foi estratificada em 80% treino e 20% teste, com random_state=42.

Conjunto	Total	Classe 1	Proporção positiva
Base limpa	1.018	137	13,46%
Treino	814	110	13,51%
Teste	204	27	13,24%

O relatório da Etapa 3 também registra uma verificação de sobreposição entre treino e teste, sem amostras idênticas compartilhadas.

5.3 Outliers, padronização e feature engineering

Os outliers foram sinalizados pelo critério IQR, calculado no conjunto de treinamento para registro, e mantidos por serem considerados plausíveis. Não houve remoção automática de valores extremos.

O StandardScaler foi ajustado exclusivamente com X_train. Os parâmetros aprendidos no treino foram aplicados a X_train e X_test. Assim, o conjunto de teste não participou do ajuste da transformação, reduzindo o risco de vazamento de dados.

A Etapa 3 avaliou variáveis derivadas candidatas, como total_acidity, bound_so2 e so2_ratio. As duas primeiras foram descartadas por redundância elevada com variáveis existentes; so2_ratio foi registrada como candidata opcional, mas nenhuma nova feature foi incorporada ao conjunto final.

Decisão	Resultado
Valores ausentes	Nenhum; sem imputação.
Duplicatas	125 cópias excedentes removidas.
Id e quality	Excluídos das preditoras.
Outliers	Mantidos; sem remoção automática.
Padronização	StandardScaler ajustado somente no treino.

Decisão	Resultado
Feature engineering	Nenhuma variável nova incluída na versão final.
Desbalanceamento	Sem reamostragem nesta etapa; uso de class_weight e métricas adequadas na modelagem.

6. Desenvolvimento dos modelos

6.1 Regressão Logística

A Regressão Logística foi treinada com as variáveis padronizadas. A configuração registrada inclui class_weight='balanced', max_iter=1000 e random_state=42. O balanceamento de pesos busca considerar a menor frequência da classe positiva.

6.2 Random Forest

O Random Forest foi treinado com as variáveis na escala original, adequada ao modelo baseado em árvores. A configuração registrada utiliza 200 estimadores, class_weight='balanced', random_state=42 e n_jobs=-1.

6.3 Ajuste do limiar de decisão

Além do limiar padrão, foi avaliado o ponto de corte 0,25 para a probabilidade da classe positiva. A seleção ocorreu por validação cruzada estratificada com cinco divisões no conjunto de treinamento. Foram examinados limiares de 0,10 a 0,90 em incrementos de 0,05, utilizando probabilidades fora da respectiva dobra de treinamento.

Fase	Precisão	Recall	F1-score
Validação cruzada — limiar 0,25	43,31%	61,82%	50,94%
Teste reservado — limiar 0,25	54,05%	74,07%	62,50%

Separação metodológica O limiar foi escolhido na validação cruzada do conjunto de treinamento e depois aplicado ao conjunto de teste reservado. O desempenho de teste não foi usado para escolher o limiar.

7. Avaliação e comparação

As métricas abaixo correspondem ao conjunto de teste de 204 amostras, incluindo 27 exemplos da classe positiva. Precisão, recall e F1-score são apresentados para a classe 1.

Métrica	Regressão Logística	Random Forest padrão	Random Forest — 0,25
Acurácia	78,43%	90,69%	88,24%
Precisão	35,59%	90,00%	54,05%
Recall	77,78%	33,33%	74,07%
F1-score	48,84%	48,65%	62,50%
AUC-ROC	0,8818	0,9317	0,9317

7.1 Matrizes de confusão

As matrizes de confusão permitem observar quantos exemplos de cada classe foram classificados corretamente e quantos foram confundidos.

Modelo	TN	FP	FN	TP
Regressão Logística	139	38	6	21
Random Forest padrão	176	1	18	9
Random Forest — limiar 0,25	160	17	7	20

TN: verdadeiros negativos; FP: falsos positivos; FN: falsos negativos; TP: verdadeiros positivos.

7.2 Leitura comparativa

- A Regressão Logística identificou 21 dos 27 vinhos de alta qualidade, mas gerou 38 falsos positivos.
- O Random Forest padrão apresentou precisão de 90%, mas identificou somente 9 dos 27 exemplos positivos.
- O Random Forest com limiar 0,25 identificou 20 dos 27 exemplos positivos, com 17 falsos positivos.
- A configuração com limiar 0,25 apresentou o maior F1-score (62,50%) entre as configurações comparadas.

A AUC-ROC do Random Forest permaneceu em 0,9317 após a alteração do limiar porque a mudança do ponto de corte não altera as probabilidades produzidas nem sua ordenação; altera apenas a conversão dessas probabilidades em rótulos.

Modelo recomendado no escopo do projeto Random Forest com limiar 0,25. A recomendação prioriza melhor equilíbrio entre precisão e recall da classe positiva, conforme o maior F1-score observado no teste. Não significa que o modelo esteja validado para uso operacional.

8. Interpretação e implicações para a produção

A análise de correlação destacou o teor alcoólico como a variável com maior associação positiva entre as variáveis apresentadas, seguido por sulfatos e ácido cítrico; a acidez volátil apresentou associação negativa com quality.

A importância baseada nas árvores do Random Forest também destacou teor alcoólico, acidez volátil, sulfatos e ácido cítrico. A análise por permutação apresentou destaque para teor alcoólico, seguido de sulfatos, acidez volátil e ácido cítrico.

Essas medidas descrevem relevância preditiva dentro do conjunto e do modelo avaliados. Não demonstram que alterar isoladamente uma característica causará mudança na qualidade do vinho. Como implicação, os resultados podem orientar hipóteses e investigações adicionais com especialistas e dados de produção, mas não prescrevem ajustes de processo.

8.1 Aplicação possível e cautelas

- Usar as variáveis destacadas para orientar análises exploratórias e perguntas técnicas a especialistas.
- Investigar se padrões semelhantes se mantêm em outras safras, regiões, produtores e amostras.
- Validar o modelo em dados externos antes de considerar qualquer uso operacional.
- Definir com especialistas o custo relativo de falsos positivos e falsos negativos antes de escolher um limiar em contexto real.

9. Organização do projeto e reprodutibilidade

Repositório informado: https://github.com/acmrosax/Tech-Challeng

A auditoria do repositório identificou a branch main e três pull requests integrados. A estrutura observada inclui material de EDA, base WineQT, notebook e relatório de preparação da Etapa 3, notebook e relatório de Machine Learning da Etapa 4, artefatos CSV e README.md.

Componente observado	Conteúdo / finalidade
Challeng 2/Notebooks	Notebooks e materiais da análise exploratória.
Challeng 2/vinho-tech-challenge	Arquivo WineQT.csv.
Etapa3/	Notebook de preparação, relatório PDF e artefatos preparados.
Etapa 4/	Notebook de Machine Learning, relatório técnico e arquivos de treino/teste.
README.md	Descrição do projeto e instruções gerais de execução.

9.1 Histórico de integração

Pull request	Escopo registrado	Situação na auditoria
PR #1	Integração da Etapa 3 — preparação dos dados.	Merged na main.
PR #2	Etapa 4 — modelos, métricas, matrizes, limiar e validação cruzada.	Merged na main.
PR #3	Documentação e reprodutibilidade; README e ajustes.	Merged na main em 31/10/2026.

9.2 Reprodutibilidade — itens de conferência

O Trello registra como pendências de revisão a confirmação do requirements.txt, a disponibilidade dos CSVs, a reprodução em ambiente limpo/por outro integrante e a organização dos gráficos e métricas. A auditoria anterior também não localizou requirements.txt na raiz. Como a existência do arquivo pode mudar, o estado deve ser confirmado diretamente na versão atual do repositório antes da submissão.

- Confirmar e versionar requirements.txt com as dependências realmente utilizadas e suas versões, quando possível.
- Testar o README em ambiente limpo, incluindo instalação, caminhos relativos e execução dos notebooks.
- Confirmar se os dados necessários estão disponíveis no repositório ou se o README explica como obtê-los.
- Verificar se gráficos e métricas estão organizados e acessíveis em diretórios apropriados.
- Registrar versões de Python e bibliotecas usadas, caso ainda não estejam documentadas.

10. Equipe, responsabilidades e integração

Integrante	Responsabilidade registrada	Entregas associadas
Ana Carolina Mendes Rosa	Análise exploratória (EDA).	Distribuições, correlações, balanceamento, outliers e visualizações.
Gabriel Teixeira Pimenta	Pré-processamento.	Verificações, duplicatas, alvo binário, divisão treino/teste e padronização.
Rayra Godinho Viana Bahia	Machine Learning.	Regressão Logística, Random Forest, métricas, ajuste do limiar e interpretação dos modelos.
Joey da Silva Dagmar	Gestão e comunicação; integração e storytelling.	Acompanhamento do Trello, consolidação, documentação, apresentação executiva e vídeo.

A divisão acima segue as responsabilidades registradas no quadro Trello e nos materiais do projeto. A integração das etapas foi consolidada por pull requests na branch principal.

Nota sobre atribuição As responsabilidades descrevem a divisão de trabalho registrada pela equipe. Não substituem o histórico de commits nem pretendem atribuir individualmente cada linha de código.

11. Entregáveis oficiais e situação no Trello

Entregável FIAP	Evidência registrada	Situação / ação restante
1. Link do GitHub com os códigos.	Repositório existente, notebooks, dados, relatórios e README; PRs #1, #2 e #3 integrados.	Conferir dependências, dados, reprodução e acesso final.
2. Apresentação executiva em PPT/PDF com storytelling da EDA.	PDF WineQT-Tech-Challenge-FIAP_T1_1.pdf, 11 páginas, fornecido para revisão.	Apresentação produzida; Trello registra publicação no GitHub e teste do link como pendentes.
3. Vídeo executivo de até 5 minutos.	Arquivo Apresentação Tech Challenge II.mp4; duração registrada de 4min56s.	Gravação concluída; Trello mantém revisão audiovisual, confirmação do apresentador e disponibilização do link como pendentes.

11.1 Estado do Trello na consulta de 02/11/2026

O quadro registra como concluídas as etapas técnicas principais — EDA, preparação, modelagem, avaliação e interpretação — e também informa que a apresentação foi produzida e o vídeo foi gravado. A atualização geral de 01/11/2026 registra base final de 1.018 amostras, treino 814, teste 204 e Random Forest com limiar 0,25 como configuração recomendada.

Os cartões de fechamento ainda mantêm itens abertos: revisão técnica, publicação do PDF no GitHub, confirmação de requirements.txt e dados, teste em ambiente limpo, revisão de áudio/imagem, conferência dos links e submissão oficial.

Inconsistência administrativa a resolver Em alguns cartões, a descrição registra atividades já realizadas (como apresentação produzida e vídeo gravado), enquanto checklists internos continuam desmarcados. Recomenda-se atualizar os checklists para refletir o trabalho concluído, mantendo abertas apenas as verificações realmente pendentes.

12. Limitações, riscos e próximos passos

12.1 Limitações metodológicas

- A classe positiva possui somente 27 exemplos no conjunto de teste; poucas classificações alteram sensivelmente as métricas.
- O limiar foi escolhido entre valores candidatos por validação cruzada no conjunto de treinamento; sua generalização precisa ser verificada em novas amostras.
- A importância por permutação foi calculada no conjunto de teste e deve ser interpretada como análise exploratória de relevância preditiva, não como causalidade.
- Os resultados refletem a base e a divisão avaliadas; não demonstram desempenho em outras populações de vinhos.
- O modelo é uma prova de conceito e não substitui avaliação sensorial especializada.

12.2 Plano de fechamento

Prioridade	Ação	Evidência de conclusão
Alta	Confirmar requirements.txt e dependências.	Arquivo versionado e instalação testada.
Alta	Reproduzir o projeto em ambiente limpo ou por outro integrante.	Notebooks executados e caminhos validados.
Alta	Publicar o PDF executivo no GitHub.	Link abre o PDF diretamente.
Alta	Disponibilizar o vídeo e revisar áudio, imagem, duração e apresentador.	Link acessível; duração inferior a 5 minutos.
Alta	Conferir links, prazo e canal oficial e realizar a submissão.	Submissão confirmada.
Média	Atualizar checklists do Trello conforme as atividades já realizadas.	Cartões refletem o estado real.

O vídeo fornecido/registrado possui duração de 4min56s, dentro do limite de cinco minutos previsto no enunciado. A verificação de duração não substitui a revisão de conteúdo, áudio, imagem, linguagem executiva e confirmação de que ao menos um integrante apresenta o projeto.

13. Conclusão

O projeto WineQT desenvolveu uma pipeline de classificação binária que parte da análise exploratória, passa pela preparação cuidadosa dos dados e compara dois modelos supervisionados. A preparação removeu duplicatas que poderiam causar sobreposição entre treino e teste, preservou o conjunto de teste para avaliação e ajustou a padronização somente com dados de treinamento.

Entre as configurações avaliadas, o Random Forest com limiar 0,25 apresentou o maior F1-score no teste (62,50%), com recall de 74,07%, precisão de 54,05% e AUC-ROC de 0,9317. A escolha é coerente com a intenção de identificar mais amostras da classe positiva, considerando o compromisso entre falsos positivos e falsos negativos.

Os materiais consultados indicam que as principais etapas técnicas foram desenvolvidas, documentadas e integradas à branch main. A apresentação executiva e o vídeo também foram produzidos. O encerramento da entrega depende da confirmação da reprodutibilidade, da publicação e acessibilidade dos materiais, da atualização do Trello e da submissão oficial.

Veredito documental O projeto está tecnicamente desenvolvido em sua essência. A documentação registra o que foi realizado e distingue as entregas concluídas das verificações ainda pendentes. A conclusão administrativa deve ocorrer somente após a confirmação dos três entregáveis e da submissão.

14. Fontes e materiais consultados

- Enunciado oficial FIAP: “POSTECH - DTAT - Tech Challenge - Fase 2” (PDF, 6 páginas), especialmente páginas 2 a 5 — contexto, etapas e entregáveis.
- Repositório GitHub: https://github.com/acmrosax/Tech-Challeng
- Quadro Trello: https://trello.com/b/jd4NwC6e/meu-quadro-do-trello — cartões de narrativa executiva, revisão técnica, vídeo, conferência final, progresso e critérios de conclusão.
- Apresentação executiva: WineQT-Tech-Challenge-FIAP_T1_1.pdf (11 páginas).
- Relatório da Etapa 3: Relatorio_Etapa3_Preparacao_WineQT.pdf (6 páginas).
- Relatório técnico de Machine Learning: Relatorio_Machine_Learning_WineQT.docx (5 páginas).
- Documentação técnica anterior: Documentacao_Tecnica_Tech_Challenge_WineQT.docx e PDF (7 páginas).
- Vídeo executivo: Apresentação Tech Challenge II.mp4 — duração registrada de 4min56s.

- Notebooks citados nos relatórios: Etapa3_Preparacao.ipynb e Etapa4_Machine_Learning_WineQT.ipynb.

Nota de rastreabilidade: as informações técnicas e métricas foram transcritas dos relatórios, da apresentação e do estado do repositório/Trello consultados. Onde a situação pode mudar — por exemplo, publicação dos arquivos, presença de requirements.txt e submissão — o documento recomenda confirmação no momento da entrega, em vez de presumir conclusão.