TECH CHALLENGE

WineQT

Classificação da qualidade de vinhos com Machine Learning

Documentação técnica e executiva do projeto

Finalidade: Registrar o problema, os dados, as etapas realizadas, a abordagem de preparação e modelagem, os resultados, a divisão de responsabilidades e o estado dos entregáveis. Este documento complementa o repositório, os notebooks, a apresentação executiva e o vídeo; não substitui nenhum deles.

FIAP • Tech Challenge — Fase 2
Equipe WineQT
02 de novembro de 2026

1. Visão geral do projeto

O projeto WineQT investiga como características físico-químicas de amostras de vinho podem ser utilizadas para classificar sua qualidade em duas categorias. A proposta é construir e comparar modelos de classificação que apoiem a análise da qualidade, utilizando dados estruturados em vez de depender exclusivamente de avaliação sensorial.

A classificação binária adotada transforma a variável original quality em um alvo com duas classes: alta qualidade, para notas iguais ou superiores a 7, e baixa/média qualidade, para notas inferiores a 7.

Elemento	Definição adotada
Problema	Classificar a qualidade do vinho a partir de medições físico-químicas.
Base	Wine Quality Dataset (WineQT), obtida do Kaggle, conforme os materiais do projeto.
Variável-alvo	quality_class: 1 se quality ≥ 7; 0 se quality < 7.
Preditoras	11 características físico-químicas.
Modelos	Regressão Logística e Random Forest.
Objetivo de avaliação	Comparar desempenho e interpretar os erros com métricas de classificação.

Escopo e interpretação: O modelo é uma ferramenta de apoio à análise e uma prova de conceito. Os resultados não demonstram causalidade nem validam o uso direto em produção.

2. Contexto e objetivo

A avaliação tradicional de vinhos envolve análise sensorial e depende da experiência de especialistas. O trabalho explora se padrões presentes em medições físico-químicas podem contribuir para prever a classe de qualidade.

O objetivo técnico é treinar e avaliar classificadores capazes de estimar se uma amostra pertence à classe de alta qualidade (nota ≥ 7), usando as variáveis disponíveis.

2.1 Variáveis utilizadas

Variável no conjunto de dados	Descrição
fixed acidity	Acidez fixa
volatile acidity	Acidez volátil
citric acid	Ácido cítrico
residual sugar	Açúcar residual
chlorides	Cloretos
free sulfur dioxide	Dióxido de enxofre livre
total sulfur dioxide	Dióxido de enxofre total
density	Densidade
pH	pH
sulphates	Sulfatos
alcohol	Teor alcoólico

3. Dados e análise exploratória (EDA)

A análise exploratória inicial considerou 1.143 registros. Foram examinadas a estrutura da base, as distribuições das variáveis, a distribuição das notas de qualidade, as relações entre variáveis, os possíveis valores atípicos e o balanceamento da classificação.

Medida apresentada na EDA	Quantidade	Percentual
Nota 5	483	42,3%
Nota 6	462	40,4%
Nota 7	143	12,5%
Nota 8	16	1,4%
Notas 3 e 4 agrupadas	39	3,4%

As notas 5 e 6 concentram 82,7% dos registros. As notas 7 e 8 representam 13,9% da base, o que evidencia que a classe de alta qualidade é minoritária. A média de qualidade informada na apresentação é aproximadamente 5,66.

3.1 Correlações destacadas

Variável	Correlação com quality	Leitura apresentada
Álcool	+0,485	Associação positiva mais forte entre as variáveis destacadas.
Acidez volátil	−0,407	Associação negativa com quality.
Sulfatos	+0,258	Associação positiva.
Ácido cítrico	+0,241	Associação positiva.

A análise de outliers pelo IQR destacou açúcar residual e cloretos. O material do projeto ressalta corretamente que correlação indica associação, não causalidade.

4. Pré-processamento dos dados

Após a análise exploratória, a preparação da base produziu 1.018 registros para a modelagem. A divisão apresentada foi de 814 amostras para treinamento e 204 para teste.

- Definição do alvo binário quality_class com limiar de qualidade igual a 7.
- Verificação de valores ausentes, duplicatas e possíveis inconsistências de domínio.
- Remoção de duplicatas conforme a lógica documentada no notebook de preparação.
- Exclusão de Id e quality do conjunto de preditores: Id é identificador e quality é a origem do alvo, portanto não deve entrar como variável preditora.
- Separação estratificada entre treino e teste, com test_size de 20% e random_state 42.
- Sinalização de outliers pelo critério IQR; o notebook registra que foram mantidos, sem remoção automática.
- Ajuste do StandardScaler somente com os dados de treino e aplicação da transformação ao conjunto de teste.
- Exportação dos conjuntos de dados preparados, do scaler e de um registro das decisões de preparação.

Prevenção de vazamento: O scaler é ajustado apenas no conjunto de treinamento. O conjunto de teste é transformado com os parâmetros aprendidos no treino, permanecendo separado para a avaliação final.

Conjunto	Quantidade de registros
Base após preparação	1.018
Treinamento	814
Teste	204

5. Desenvolvimento dos modelos

5.1 Regressão Logística

A Regressão Logística foi treinada utilizando as variáveis padronizadas. A configuração registrada inclui class_weight='balanced', max_iter=1000 e random_state=42.

5.2 Random Forest

O Random Forest foi treinado com as variáveis na escala original. A configuração registrada utiliza 200 estimadores, class_weight='balanced', random_state=42 e n_jobs=-1.

5.3 Ajuste do limiar

Além da classificação padrão, foi avaliado um limiar de decisão de 0,25 para a probabilidade da classe positiva. O notebook registra o uso de validação cruzada estratificada com cinco divisões sobre o conjunto de treinamento para examinar limiares. O limiar de 0,25 foi então aplicado às probabilidades do conjunto de teste.

Por que ajustar o limiar? O Random Forest padrão apresentou alta precisão, mas recall menor. Com o limiar 0,25, o modelo identificou mais exemplos positivos, elevando o recall e o F1-score, com redução da precisão.

6. Avaliação e resultados

Os resultados abaixo são os apresentados na apresentação executiva para o conjunto de teste.

Modelo	Acurácia	Precisão	Recall	F1-score	AUC
Regressão Logística	78,43%	35,59%	77,78%	48,84%	0,8818
Random Forest padrão	90,69%	90,00%	33,33%	48,65%	0,9317
Random Forest — limiar 0,25	88,24%	54,05%	74,07%	62,50%	0,9317

Entre as configurações comparadas, o Random Forest com limiar 0,25 apresentou o maior F1-score (62,50%). A apresentação informa que essa configuração encontrou 20 dos 27 exemplos positivos do conjunto de teste.

A escolha prioriza maior capacidade de identificar a classe positiva, aceitando mais falsos positivos do que a configuração padrão. A decisão deve ser interpretada à luz do objetivo do projeto e do custo relativo de falsos positivos e falsos negativos.

Limitação: O desempenho é medido em uma única divisão de teste da base disponível. A apresentação recomenda validação em novos conjuntos de dados antes de qualquer aplicação operacional.

7. Interpretação e implicações

As correlações destacadas sugerem associação entre algumas características físico-químicas e a nota de qualidade. O teor alcoólico apresentou a maior correlação positiva entre as variáveis destacadas, enquanto a acidez volátil apresentou associação negativa.

Esses achados podem orientar investigações adicionais sobre o processo produtivo e apoiar a formulação de hipóteses para avaliação por especialistas. Entretanto, não permitem afirmar que alterar isoladamente uma característica causará aumento da qualidade. A interpretação deve considerar interações entre variáveis, contexto de produção e validação externa.

A importância de variáveis calculada pelo Random Forest também foi explorada no notebook. A documentação executiva deve apresentar essas medidas como sinais de relevância preditiva no modelo, não como prova de causalidade.

8. Organização do repositório e reprodutibilidade

Repositório GitHub informado e revisado durante a auditoria:

https://github.com/acmrosax/Tech-Challeng

A estrutura observada inclui os notebooks e resultados da EDA, a base WineQT, a pasta Etapa3 com notebook, relatório e artefatos preparados, a pasta Etapa 4 com notebook, relatório e arquivos de treino/teste, além do README.md.

Componente	Conteúdo observado
Challeng 2/Notebooks	Scripts e notebook de análise exploratória, resultados e gráficos.
Challeng 2/vinho-tech-challenge	Arquivo WineQT.csv.
Etapa3/	Notebook de preparação, relatório PDF e dados preparados.
Etapa 4/	Notebook de Machine Learning, relatório DOCX e arquivos CSV de treino/teste.
README.md	Descrição e instruções gerais do projeto.

Na auditoria do repositório, não foi localizado um arquivo requirements.txt na raiz. A criação e validação desse arquivo permanecem como ação recomendada para facilitar a reprodução do ambiente.

Também permanece importante testar o fluxo em ambiente limpo ou com outro integrante, verificando caminhos relativos, disponibilidade dos dados, dependências e execução dos notebooks.

9. Histórico de integração

Pull request	Descrição	Estado observado
PR #1	Integração da Etapa 3 — preparação dos dados.	Integrado à main.
PR #2	Etapa 4 — modelos, métricas, matrizes de confusão, limiar e validação cruzada.	Integrado à main.
PR #3	Documentação e reprodutibilidade.	Integrado à main em 31/10/2026.

A auditoria consultada identificou os três PRs como integrados à branch main. Esse histórico demonstra a consolidação das contribuições no repositório principal.

10. Equipe e divisão de responsabilidades

Integrante	Responsabilidade registrada	Entregas associadas
Ana Carolina Mendes Rosa	Análise exploratória dos dados (EDA).	Distribuições, correlações, balanceamento, outliers e visualizações.

Gabriel Teixeira Pimenta	Pré-processamento dos dados.	Tratamento, preparação, divisão treino/teste e padronização.
Rayra Godinho Viana Bahia	Desenvolvimento dos modelos.	Regressão Logística, Random Forest, métricas, ajuste de limiar e interpretação do modelo.
Joey da Silva Dagmar	Interpretação e storytelling; gestão e comunicação no Trello.	Consolidação, documentação, apresentação executiva e vídeo.

A divisão acima segue os papéis registrados nos materiais do projeto e no Trello. A integração final é uma atividade compartilhada, coordenada na etapa de consolidação.

11. Entregáveis oficiais e estado da entrega

Entregável previsto no enunciado	Evidência disponível	Ação de fechamento
Link do repositório GitHub com os códigos.	Repositório existente, com notebooks, dados, relatórios e README.	Revisar acesso, dependências e reprodução.
Apresentação executiva em PPT ou PDF, com storytelling da EDA.	PDF WineQT-Tech-Challenge-FIAP_T1_1.pdf, com 11 páginas, fornecido para revisão.	Confirmar que o PDF está publicado no GitHub e testar o link.
Vídeo executivo de até 5 minutos, com integrante apresentando e linguagem executiva.	MP4 fornecido; duração verificada de 4min56s.	Revisar áudio/imagem, confirmar apresentador e disponibilizar link acessível.

Sobre esta documentação: O enunciado oficial consultado exige o repositório, a apresentação executiva e o vídeo. Não estabelece um documento DOCX ou um relatório geral separado como quarto entregável obrigatório. Este arquivo é uma documentação complementar para explicar e organizar o projeto; não substitui os três entregáveis oficiais.

11.1 Checklist de fechamento

- ☐ Criar e versionar requirements.txt com as dependências efetivamente utilizadas.
- ☐ Executar os notebooks em ambiente limpo ou solicitar a outro integrante que reproduza o fluxo.
- ☐ Confirmar que os arquivos de dados e os caminhos usados nas instruções estão acessíveis.
- ☐ Conferir a consistência dos números entre notebooks, relatórios, apresentação e vídeo.
- ☐ Publicar a apresentação PDF no repositório e testar o link.
- ☐ Disponibilizar o vídeo em local acessível e testar o link.
- ☐ Conferir o canal, o prazo e as instruções de submissão da turma.
- ☐ Realizar a submissão e guardar a confirmação.

12. Conclusão

O projeto desenvolveu uma pipeline de classificação binária da qualidade de vinhos, desde a análise exploratória até a comparação de modelos. A base foi preparada, foram treinados dois classificadores e o Random Forest com limiar 0,25 apresentou o maior F1-score entre as configurações reportadas.

Os materiais consultados indicam que as principais etapas técnicas foram realizadas e integradas ao repositório. O trabalho está em fase de consolidação dos entregáveis, com foco em dependências, reprodutibilidade, publicação da apresentação e do vídeo e confirmação da submissão.

Conclusão geral: O projeto está tecnicamente desenvolvido em sua essência, mas o estado de entrega só deve ser considerado concluído após a validação dos links, da reprodução e da submissão oficial.

Fontes utilizadas para esta documentação

- Enunciado oficial: POSTECH - DTAT - Tech Challenge - Fase 2 (PDF de 6 páginas).
- Repositório GitHub: https://github.com/acmrosax/Tech-Challeng
- Quadro Trello: https://trello.com/b/jd4NwC6e/meu-quadro-do-trello
- Apresentação executiva: WineQT-Tech-Challenge-FIAP_T1_1.pdf (11 páginas).
- Vídeo executivo: Apresentação Tech Challenge II.mp4 (duração informada/verificada: 4min56s).
- Notebooks e relatórios das Etapas 2, 3 e 4 presentes no repositório.

Nota de precisão: o documento foi elaborado com base no enunciado, nos materiais compartilhados, no estado do GitHub e do Trello consultados na auditoria. Itens não confirmados nos arquivos foram identificados como pendentes de conferência, em vez de serem presumidos como concluídos.