FIAP

TECH CHALLENGE

WineQT

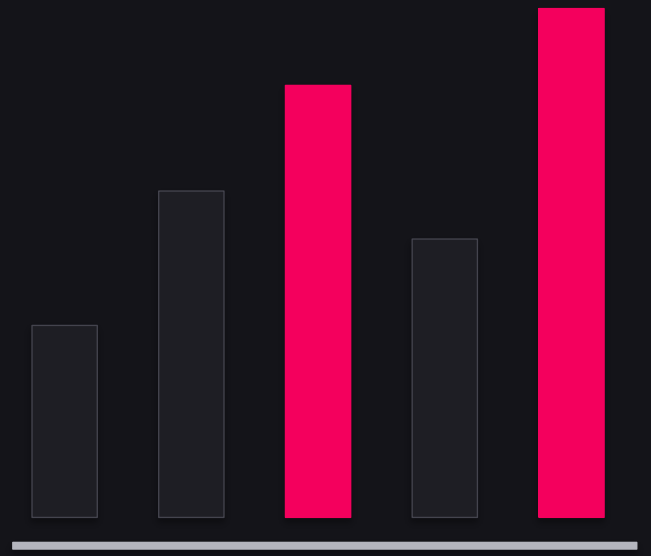
Classificação da qualidade de vinhos com

Machine Learning

Da análise exploratória à avaliação de modelos preditivos

PROJETO DE CLASSIFICAÇÃO BINÁRIA

DO DADO À DECISÃO



11 variáveis físico-químicas

2 modelos comparados

01 / O desafio

Como os dados físico-químicos podem ajudar a classificar a qualidade de um vinho?

- A avaliação sensorial é tradicionalmente subjetiva e depende da experiência do avaliador.
- O projeto investiga padrões nos dados que ajudem a prever a classificação.
- O modelo é uma ferramenta de apoio à análise, não um substituto do especialista.

OBJETIVO DO PROJETO

Prever se um vinho é de alta qualidade (nota ≥ 7) com base em suas características físico-químicas.

FIAP

Tech Challenge
Classificando a qualidade de vinhos com Machine Learning



Qualidade do Vinho

Composição Físico-Química

Análise de características que influenciam a qualidade do vinho

Acidez
- Acidez fixa
- Acidez volátil
- Ácido cítrico
- pH

Conservação
- SO_2 livre
- SO_2 total

Composição
- Açúcar residual
- Cloretos
- Sulfatos

Propriedades
- Densidade
- Teor alcoólico

Machine Learning
Análise das características físico-químicas

Classificação da Qualidade

Classe 0	Classe 1
Qualidade abaixo de 7	Qualidade ≥ 7

Destaque da análise
As variáveis que mais se destacaram no projeto foram teor alcoólico, acidez volátil, sulfatos e ácido cítrico.

Legenda das Variáveis

Acidez fixa	Acidez volátil	Ácido cítrico	Açúcar residual	Cloretos	SO_2 livre	SO_2 total	Densidade	pH	Sulfatos	Álcool
Ácidos naturais presentes no vinho	Principalmente ácidos voláteis, como o acético	Concentração de ácido cítrico	Açúcar que permanece após a fermentação	Concentração de sais de cloreto	Dióxido de enxofre em forma livre	Quantidade total de dióxido de enxofre	Massa por unidade de volume	Nível de acidez ou alcalinidade	Concentração de sulfatos	Teor alcoólico do vinho

02 / Conhecendo os dados

FONTE E ESTRUTURA

Wine Quality Dataset — Kaggle

- 11 características físico-químicas usadas como variáveis preditoras.
- Alvo binário: alta qualidade (nota ≥ 7) e baixa/média (nota < 7).
- A EDA inicial analisou 1.143 registros; após preparação, 1.018 foram usados na modelagem.

BASE ANALISADA NA EDA

1.143

BASE PARA MODELAGEM

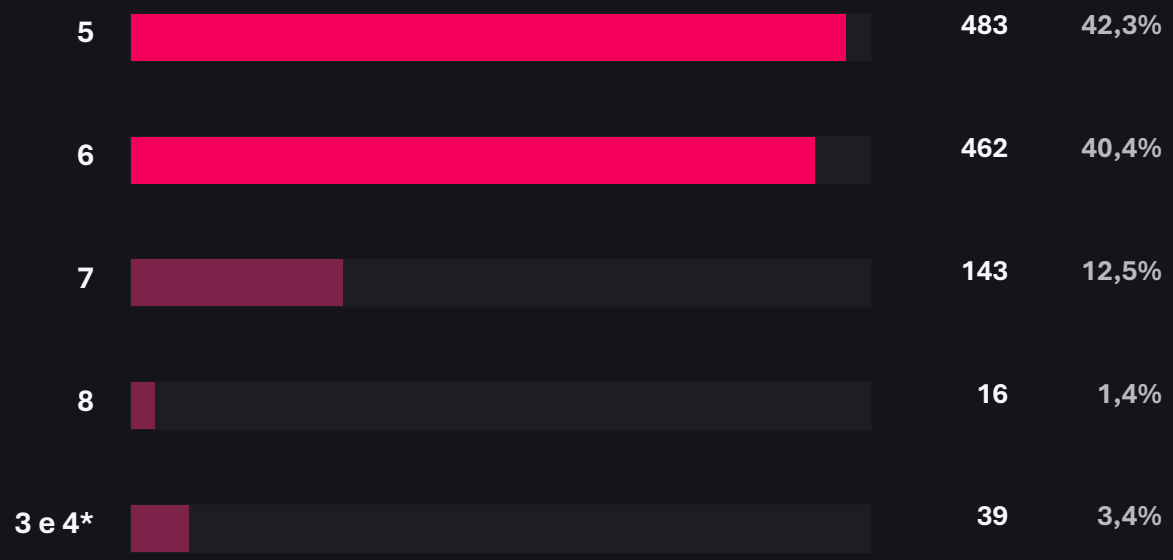
1.018

Treino 814 | Teste 204

03 / O que a EDA revelou

Distribuição das notas de qualidade

Frequência por nota — base da EDA (n = 1.143)



*Notas 3 e 4 agrupadas: total residual de 39 registros.

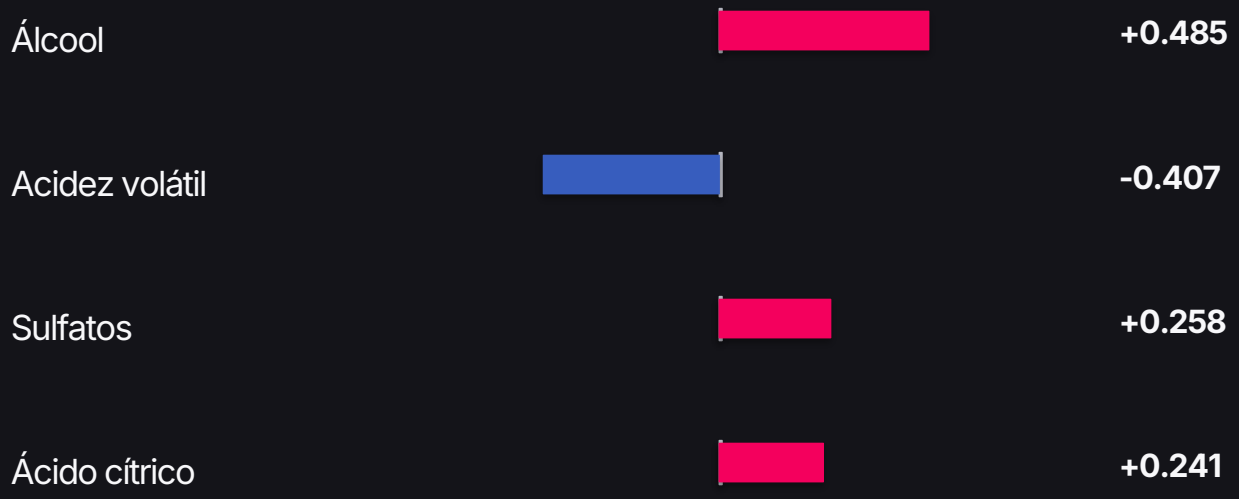
PRINCIPAIS INSIGHTS

- As notas 5 e 6 concentram 82,7% dos registros.
- As notas 7 e 8 representam 13,9% da base.
- A classe de alta qualidade (nota ≥ 7) é minoritária.

Média de qualidade: aproximadamente 5,66.

04 / Relações e valores atípicos

Correlação com a variável quality



Correlação indica associação, não causalidade.

LEITURA DOS RESULTADOS

- Álcool: associação positiva mais forte entre as variáveis destacadas.
- Acidez volátil: associação negativa com quality.
- Açúcar residual e cloretos se destacaram na análise de outliers pelo IQR.

05 / Preparação para a modelagem

01

Preparação

Tratamento e conferência dos dados

02

Padronização

Escalonamento das variáveis numéricas

03

Separação

Treino: 814
Teste: 204

04

Base final

1.018 registros
11 variáveis

O conjunto de teste foi mantido separado para a avaliação final.

06 / Comparação dos modelos

Resultados no conjunto de teste

Modelo	Acurácia	Precisão	Recall	F1-score	AUC
Regressão Logística	78,43%	35,59%	77,78%	48,84%	0,8818
Random Forest padrão	90,69%	90,00%	33,33%	48,65%	0,9317
Random Forest — limiar 0,25	**88,24%**	**54,05%**	**74,07%**	**62,50%**	**0,9317**

O Random Forest com limiar 0,25 apresentou o maior F1-score: 62,50%.

07 / Por que ajustar o limiar?

RANDOM FOREST PADRÃO

Precisão: 90,00%

Recall: 33,33%

Com o limiar padrão, o modelo é mais seletivo, mas identifica menos vinhos da classe positiva.

RANDOM FOREST — LIMIAR 0,25

Precisão: 54,05%

Recall: 74,07%

O ajuste aumentou a identificação de positivos: 20 dos 27 exemplos positivos foram encontrados.

F1-score: 62,50% | AUC: 0,9317

08 / Conclusão e próximos passos

CONCLUSÕES

- O conjunto de dados contém sinais úteis para apoiar a classificação.
- Random Forest com limiar 0,25 apresentou melhor F1-score entre os modelos avaliados.
- O resultado é uma prova de conceito, não uma validação de produção.

PRÓXIMOS PASSOS

- Validar em novos conjuntos de dados.
- Testar outros algoritmos e hiperparâmetros.
- Conferir reprodução em ambiente limpo e dependências.

Obrigado!

09 / Integrantes

EQUIPE

Ana Carolina Mendes Rosa | RM376423
Análise exploratória dos dados (EDA)

Gabriel Teixeira Pimenta | RM376873
Pré-processamento dos dados

Joey da Silva Dagmar | RM376403
Interpretação e storytelling

Rayra Godinho Viana Bahia | RM375753
Desenvolvimento dos modelos

ORIENTAÇÃO

Ana Raquel Fernandes Cunha
Professor(a) / Orientador(a)

Edgard Kiriyama
Professor(a) / Orientador(a)